

Міністерство освіти і науки України
Національний технічний університет України
“Київський політехнічний інститут ім. Ігоря Сікорського”
Фізико-технічний інститут

Лабораторна робота № 1

**«Експериментальна оцінка ентропії на символ джерела відкритого
тексту»**

Виконали:

Студентки 3 курсу,
Групи ФБ-06 Вернікова
Лілія
Товкач Катерина

Мета роботи

Засвоєння понять ентропії на символ джерела та його надлишковості, вивчення та порівняння різних моделей джерела відкритого тексту для наближеного визначення ентропії, набуття практичних навичок щодо оцінки ентропії на символ джерела.

Порядок виконання роботи

0. Уважно прочитати методичні вказівки до виконання комп'ютерного практикуму.
1. Написати програми для підрахунку частот букв і частот біграм в тексті, а також підрахунку $1H$ та $2H$ за безпосереднім означенням. Підрахувати частоти букв та біграм, а також значення $1H$ та $2H$ на довільно обраному тексті російською мовою достатньої довжини (щонайменше 1Мб), де імовірності замінити відповідними частотами. Також одержати значення $1H$ та $2H$ на тому ж тексті, в якому вилучено всі пробіли.
2. За допомогою програми CoolPinkProgram оцінити значення $10(H)$, $20(H)$, $30(H)$.
3. Використовуючи отримані значення ентропії, оцінити надлишковість російської мови в різних моделях джерела.

Хід роботи

Знайшли текст, який будемо досліджувати, потім зчитали його та очистили від зайвих символів, отриманий текст зберегли у файлі, також зберегли цей самий текст, але без пробілів у іншому файлі. Для очистки використали фільтр де перевіряли чи належить символ з тексту до нашого алфавіту. Після ми спочатку написали функції для пошуку монограм, але в подальшому вирішили оптимізувати код і зробили одну велику функцію де містяться всі інші функції що ми будемо використовувати. У цій функції ми одразу шукали монограму і біграми. Отримані дані записуємо в csv використовуючи бібліотеку pandas.

Результати

Текст з пробілами: монограми:

Ентропія: 4.374552813221424

Надлишковість: 0.1250894373557152

біграми з перетином:

Ентропія: 3.982927743685439

Надлишковість: 0.20341445126291213

біграми без перетину:

Ентропія: 3.9827166848356628

Надлишковість: 0.20345666303286747

Текст без пробілів:

монограми:

Ентропія: 4.449295156504394

Надлишковість:

0.10191383672542709 біграми з

перетином: Ентропія:

4.143456816967816

Надлишковість: 0.16364702620267146

біграми без перетину:

Ентропія: 4.143254433060141

Надлишковість: 0.16368787720957445 Найчастіша поява монограм

Монограми без пробілів

Буква	к-сть	Частота
о	51247	0.11113183283926469
а	40412	0.08763556166605586
е	37479	0.08127519587454488
и	30990	0.06720345580597523

н	29234	0.0633954768322646
т	27982	0.060680448543491416
л	24261	0.05261126303029252
с	23145	0.050191157942216735
р	22203	0.04814838106679794
в	21527	0.04668243927509612
к	16813	0.036459880686216896
м	13893	0.03012770608300787
у	13698	0.0297048382584785
д	13103	0.028414549255427347
п	12855	0.02787674812474384
г	9139	0.019818405376276466
я	8841	0.019172176598277735
ь	8640	0.018736297456070538
з	8298	0.017994652348434413
ы	8030	0.017413480158824816
ч	7150	0.015505153566076893
б	7104	0.015405400130546887
й	5220	0.011319846379709285
ж	4160	0.009021180256626555
ш	3973	0.00861566085566762
х	3760	0.008153759078104771
ю	2531	0.00548860750709659
щ	1664	0.003608472102650622
ц	1474	0.003196447042852775
э	1414	0.0030663338660745073
ф	897	0.001945191992835101

Монограми з пробілами

Буква	к-сть	Частота
	86933	0.1586166000693342
о	51247	0.09350447935482693
а	40412	0.0737351068294196
е	37479	0.06838360063495538
и	30990	0.05654387213312168

н	29234	0.05333990183735654
т	27982	0.05105552210484062
л	24261	0.04426624336307406
с	23145	0.04223000711587936
р	22203	0.04051124856313974
в	21527	0.03927782947433722
к	16813	0.030676738372835587
м	13893	0.02534895177623296
у	13698	0.024993157808309158
д	13103	0.02390753006002883
п	12855	0.023455033116207783
г	9139	0.016674877296695676
я	8841	0.016131151130330066
ь	8640	0.015764409655700914
з	8298	0.015140401773496086
ы	8030	0.014651413140657215
ч	7150	0.013045778823872863
б	7104	0.012961847939131863
й	5220	0.009524330833652636
ж	4160	0.007590271315707848
ш	3973	0.007249074023391173
х	3760	0.006860437535351324
ю	2531	0.004618023245205904
щ	1664	0.003036108526283139
ц	1474	0.0026894374806137903
э	1414	0.0025799624135603117
ф	897	0.0016366522524495046

Біграми

Неперехресна та перехресна біграми з пробілами

Буква	к-сть	Частота
о	5773	0.02106665206999106
а	4911	0.017921068476654443
п	4574	0.0166912985567537
в	4512	0.016465050084843176
и	4424	0.016143923221486306
е	4384	0.015997956465415002
н	4175	0.015235280164942435
с	4048	0.014771835714416042
то	3564	0.013005637965953254
и	2955	0.01078329410476764
к	2694	0.009830861021402376
о	2668	0.009735982629956027
но	2633	0.009608261718393636
ь	2594	0.009465944131224114
на	2565	0.009360118233072418
ст	2480	0.009049938876420895
по	2460	0.008976955498385243
я	2459	0.00897330632948346
ко	2377	0.008674074479537285
не	2366	0.008633933621617677
ал	2315	0.008447826007626762
ро	2212	0.008071961610743153
л	2131	0.007776378929698761
ла	2122	0.007743536409582717

Буква	к-сть	Частота
о	11312	0.020639736967425635
а	9955	0.01816377134995776
п	9151	0.016696802774833097
в	8866	0.01617679525753144
и	8857	0.01616037396751139
е	8833	0.01611658386079125
н	8382	0.015293694772008634
с	7993	0.014583930125586377
то	7214	0.013162576244961857
и	5890	0.010746822024234175
к	5384	0.009823580607551239
о	5319	0.009704982401850863
но	5306	0.009681262760710787
ь	5214	0.009513400684950253
я	5098	0.00930174850246958
ст	5073	0.009256133807969434
на	5049	0.009212343701249296
по	4944	0.009020761984348686
не	4783	0.008727003351767753
ко	4760	0.008685037832827619
ал	4713	0.008599282207167346
ро	4444	0.008108468094345785
л	4268	0.007787340645064764
го	4250	0.0077544980650246596

Неперехресна та перехресна біграми без пробілів

Буква	к-сть	Частота
то	3691	0.016008292564449533
но	2698	0.011701537073661566
ст	2591	0.011237465736789147
на	2528	0.010964227473023143
по	2503	0.010855799590576316
ов	2494	0.010816765552895458
ко	2478	0.01074737170812949
ал	2383	0.010335345754831547
не	2369	0.010274626140661323
ро	2305	0.009997050761597447
ла	2254	0.00977585788140592
го	2193	0.009511293848235661
от	2127	0.009225044238576039
ра	2113	0.009164324624405815
ос	2079	0.009016862704278131
ен	2037	0.00883470386176746
он	2021	0.008765310017001492
ка	1991	0.0086351965580653
ни	1960	0.008500745983831234
ло	1909	0.008279553103639706
во	1891	0.008201485028277992
ор	1874	0.008127754068214149
ан	1841	0.007984629263384339
ол	1829	0.00793258387980986

Буква	к-сть	Частота	Ентропія
то	7439	0.016131900350438915	0.09604836339559475
но	5415	0.011742739668991361	0.07529547014335537
ст	5165	0.011200600256757226	0.07258302739160925
на	5076	0.011007598626001874	0.07160835238127837
ов	5027	0.010901339301203983	0.07106965508688676
по	4946	0.010725686131640124	0.07017587172909275
ал	4907	0.010641112383331599	0.0697440555791034
ко	4887	0.010597741230352868	0.06952223571450408
не	4803	0.010415582387842199	0.06858778364937902
ро	4521	0.009804049130842095	0.06541660183999268
ла	4378	0.00949394538704417	0.06378769747991177
го	4264	0.009246729815065404	0.06247868359499733
от	4259	0.009235887026820721	0.062421054260072696
ра	4168	0.009038548280767496	0.0613689698967814
ен	4109	0.00891060337948024	0.060683536088198736
ос	4093	0.008875906457097255	0.06049720047809504
он	4090	0.008869400784150445	0.060462240789665715
ни	4028	0.008734950209916381	0.059738191758063795
ка	3907	0.008472554734395059	0.05831648606624988
ор	3798	0.008236181950660976	0.05702574727997404
во	3775	0.008186305124735435	0.05675214841338552
ан	3723	0.008073540126990736	0.05613195680458713
ол	3722	0.0080713715693418	0.056120007874980705
ло	3709	0.008043180319905625	0.0559645952167137

Лабораторная работа №1

Произвольная часть текста:
аняты_будете_в_это_время_что_же_касается_вашего_поведения_с_женой_или_мужем

Использованные буквы:
у.

Порядок n-граммы:
5 символов
10 символов
15 символов
20 символов
25 символов
30 символов
35 символов
40 символов
45 символов
50 символов

Введенный символ: e

Символ по счету: 2

Номер эксперимента: 50

Неравенство для энтропии:
 $1.92095336609192 < H < 2.57923653616828$

Двоичная таблица угаданных символов:

10000000000000000000000000000000
10000000000000000000000000000000
10000000000000000000000000000000
01000000000000000000000000000000
10000000000000000000000000000000

Вероятности:

q[1] = 0,52
q[2] = 0,12
q[3] = 0,06
q[4] = 0,06
q[5] = 0
q[6] = 0
q[7] = 0,02
q[8] = 0
q[9] = 0
q[10] = 0
q[11] = 0,02
q[12] = 0
q[13] = 0
q[14] = 0
q[15] = 0,02
q[16] = 0,02
q[17] = 0,02
q[18] = 0
q[19] = 0,04
q[20] = 0
q[21] = 0,04
q[22] = 0,02
q[23] = 0
q[24] = 0
q[25] = 0,04
q[26] = 0
q[27] = 0
q[28] = 0
q[29] = 0
q[30] = 0
q[31] = 0
q[32] = 0

Поле ввода символов:
e

Продолжить Другой

Строка состояния:
Вы угадали. Для продолжения опыта нажмите "Продолжить", или "Другой" для выбора другого порядка

R= 0.54998100977398

Лабораторная работа №1

Произвольная часть текста:
есто_того_кто_занял_его_первым_или_что_ему_дали_кусочек_апельсина_совсем_пр

Использованные буквы:

Порядок n-граммы:
5 символов
10 символов
15 символов
20 символов
25 символов
30 символов
35 символов
40 символов
45 символов
50 символов

Введенный символ: _ (пробел)

Символ по счету: 1

Номер эксперимента: 50

Неравенство для энтропии:
 $1.34055655202928 < H < 1.94902928816026$

Двоичная таблица угаданных символов:

10000000000000000000000000000000
10000000000000000000000000000000
01000000000000000000000000000000
10000000000000000000000000000000
10000000000000000000000000000000

Вероятности:

q[1] = 0,62
q[2] = 0,14
q[3] = 0,06
q[4] = 0,02
q[5] = 0,02
q[6] = 0
q[7] = 0
q[8] = 0
q[9] = 0
q[10] = 0
q[11] = 0,02
q[12] = 0
q[13] = 0
q[14] = 0
q[15] = 0,06
q[16] = 0
q[17] = 0
q[18] = 0
q[19] = 0,04
q[20] = 0
q[21] = 0
q[22] = 0,02
q[23] = 0
q[24] = 0
q[25] = 0
q[26] = 0
q[27] = 0
q[28] = 0
q[29] = 0
q[30] = 0
q[31] = 0
q[32] = 0

Поле ввода символов:

Продолжить Другой

Строка состояния:
Вы угадали. Для продолжения опыта нажмите "Продолжить", или "Другой" для выбора другого порядка

R = 0.671041415981046

